



Data-Driven E-Commerce Insights with the Olist Dataset:

Analyzing Customer Satisfaction and its Drivers across Customer, Seller, Order, Review and Delivery Data



Customer



Seller



Order



Review



Delivery

Olist – Highlights



Sold Items

112,65 Tsd.



Total Sales

12,25 Mio.


Avg. Processing
Time in days

3,25

Median Processing
Time in days

2,21

Top 10 Categories [Sold Items]



Top 10 Categories [Total Sales]



**ERP Software für kleine,
mittlere lokale Händler**

mit zentraler Anbindung
an viele Marktplätze



**Produkte werden zentral
angelegt**

Produkte werden unter dem Namen
„Olist Store“ auf den angebundenen
Marktplätzen angeboten.



**Ein starkes
E-Commerce-Ökosystem
für ganz Brasilien.**

Was ist Olist?

Olist verbindet Verkäufer und Kunden.



Daten-Pipeline / Lakehouse mit AWS

Von der Rohdatenquelle zu Business-Ready-Data.



Datenquellen

Olist Daten über
Kaggle-API

- Automatischer Download über Kaggle-API
- Speicherung der Rohdaten in Amazon S3 (Bronze Layer)
- CSV-Dateien im Originalformat



Bronze

Rohdaten in S3

- Speicherung der geladenen Daten in Amazon S3
- Unveränderte Rohdaten (Raw Layer)
- Zentrale, skalierbare Speicherung



Silver

Transformation &
Bereinigung mit AWS Lambda

- Daten bereinigen und transformieren
- Datenqualität sicherstellen
- Neue, strukturierte Tabellen in S3 speichern



Gold

Datenmodellierung
mit Athena & Glue

- Tabellen als Dimensionen und Fakten modellieren
- In Athena/Glue als Views speichern
- Beziehungen zwischen den Tabellen definieren
- Optimiert für Analyse und Reporting



Consumption

Business-Ready-Data
in Power BI

- Zusätzliche Spalten, Tabellen und Measures erstellen
- Daten für Analysen und Dashboards aufbereiten
- Nutzung in Power BI für Reporting und Insights


Wie lief die Zusammenarbeit?

Gemeinsam von der Datenaufbereitung bis zum finalen Bericht.




Ausgangsdaten (Bronze-Layer)

Die Rohdaten aus der Kaggle-API als Grundlage für unsere Analyse.



Verarbeitete Daten (Silver-Layer)

Bereinigte und strukturierte Daten als Grundlage für Analyse und Reporting.





Hypothesen

Unsere Annahmen zu zentralen Einflussfaktoren auf die Kundenzufriedenheit.



Delivery

Längere Lieferzeiten bzw. Verspätungen führen zu einer **niedrigeren Kundenzufriedenheit**.



Seller Performance

Eine bessere Seller Performance führt zu einer **höheren Kundenzufriedenheit**.



Logistics Performance

Eine bessere Logistics Performance führt zu einer **höheren Kundenzufriedenheit**.



Reviews

Negative Reviews zeigen **spezifische Pain Points** in der Customer Journey.



Product

Bestimmte **Produkteigenschaften** beeinflussen die Kundenzufriedenheit.



PowerBI

Datenlimitationen & Was uns gefehlt hat

Wichtige Grenzen unserer Analyse und fehlende Daten für weiterführende Insights.



Datenlimitationen

Was wir bei der Analyse berücksichtigen mussten.

01

Beobachtungsdaten

Nur Zusammenhänge erkennbar – keine Kausalität.

02

Historischer Datensatz

Vergangene Daten – keine Aussage über zukünftige Entwicklungen.

03

Reviews $\neq$ vollständige Customer Satisfaction

Nicht alle Kunden hinterlassen eine Bewertung – potenzieller Bias.

04

Fehlende Customer-Service-/Tracking-Daten

Keine direkten Informationen zu Kundenanfragen, Support-Tickets oder detailliertem Tracking.

05

Teilweise fehlende / inkonsistente Daten

Einige Tabellen enthalten fehlende oder inkonsistente Werte, was die Analyse einschränken kann.



Was hat gefehlt? An welche Grenzen sind wir gestoßen?

Daten und Informationen, die für zusätzliche Analysen hilfreich wären.

01

Tabelle mit Produktbeständen je Seller

Aktuelle Lagerbestände pro Seller, um Stockouts und Verfügbarkeit zu analysieren.

02

Angabe der Produktverfügbarkeit / voraussichtlichem Lieferungsdatum

Informationen zur Verfügbarkeit und erwarteten Lieferzeit auf Produktebene.

03

Produktarten

Zusätzliche Produktkategorisierung (z. B. Typ, Segment), um detailliertere Analysen durchführen zu können.

04

Power BI Workspace

Zentraler Workspace für gemeinsam genutzte Dashboards und Analysen.

05

Mehrfachkäufe pro Kunde zu finden

Eindeutige Identifikation von wiederkehrenden Käufen je Kunde.

06

Komplette Postleitzahlen um alle Bereiche abdecken zu können

Vollständige und konsistente Postleitzahlen, um regionale Analysen für alle Bereiche durchführen zu können.

Was haben wir gelernt?

Technische, analytische und kollaborative Learnings aus dem Projekt.



Cloud & Data Architecture

Cloud-Technologien und Dateninfrastruktur im Projekt angewendet.

01

Arbeiten mit AWS

Erste praktische Erfahrungen mit AWS gesammelt.

02

Aufbau Data Warehouse / Lake House

Struktur für ein Data Warehouse / Lake House entwickelt.

03

AWS Athena als Datenquelle in Power BI verwenden

AWS Athena erfolgreich als Datenquelle in Power BI genutzt.



Engineering & Analytics

Datenverarbeitung, Integrationen und analytische Methoden umgesetzt.

04

APIs in KI-Systeme implementieren

APIs in KI-Systeme integriert.

05

Pipelines mit APIs zu bauen

Datenpipelines mit APIs entwickelt und umgesetzt.

06

Mapping und Joins im Preprocessing zum Anomalieausschluss verwenden

Mapping und Joins im Preprocessing genutzt, um Anomalien auszuschließen.



Team & Methods

Zusammenarbeit und methodisches Vorgehen im Projekt gestärkt.

07

Arbeit im Team und GitHub

Effektiv im Team zusammengearbeitet und GitHub für die gemeinsame Entwicklung genutzt.

08

Scrum anwenden

Scrum als methodisches Vorgehen im Projekt angewendet.

09

Galaxy Schema mit 2 Faktentabellen bauen

Ein Galaxy Schema mit zwei Faktentabellen entwickelt.

Was ist das Fazit und welche nächsten Schritte können wir Olist empfehlen?

Zentrale Erkenntnisse und konkrete Handlungsempfehlungen.



Delivery Reliability

- Lieferversögerungen reduzieren
- Lieferzeit realistisch & transparent kommunizieren



Seller Performance

- Problem-Seller identifizieren & unterstützen
- Produktverfügbarkeit durch passende Seller erhöhen



Produktverfügbarkeit

- Verfügbarkeit gefragter Produkte verbessern
- Keine zusätzliche Order-Splitting-Komplexität



Kosten & Lieferung

- Verpackungskosten optimieren
- Lieferzeiten optimieren
- Kostenlosen Versand als Option prüfen



Customer Communication

- Kunden frühzeitig über Verzögerungen informieren
- Lieferprognosen bei Änderungen aktualisieren



Reviews & Feedback

- Negative Reviews auf wiederkehrende Pain Points analysieren
- Erkenntnisse in operative Verbesserungen überführen



Vielen Dank für eure Aufmerksamkeit!

Wir freuen uns auf eure Fragen und den Austausch.



Fragen?



Feedback?



Diskussion?



**6 FÄUSTE
GEGEN RIO**